

学习笔记

1. new word

excel 擅长

default 默认/违约

retrieve 恢复, 取回

2. linux指令

a. curl

是一个命令行工具，主要用于**发送各种网络请求**，支持多种协议，适合需要精细控制请求的场景，如自定义请求头、处理复杂的 POST 请求等。

b. wget

是一个命令行工具，专注于从**网络下载文件**，支持递归下载和断点续传，适合批量下载文件或镜像整个网站的任务。

c. tar

用于创建和解压缩归档文件的工具

- 常用选项包括：
 - **-c** : 创建一个新的归档文件。
 - **-x** : 从归档文件中提取文件。
 - **-v** : 显示详细的处理信息。
 - **-f** : 指定归档文件的名称。
 - **-z** : 使用gzip压缩或解压缩。
 - **-j** : 使用bzip2压缩或解压缩。

3. 文档链接

a. 入职文档

b. 项目类别、计划

☰ 信息安全部燎原项目运营规范 附件：各类别对应输入输出内容 ☰ 燎原项目-提案分类-内部稿

c. 大部门周进展

☰ 安全水位W 管理者周会时，需要同步的部门信息水位

d. llm开发框架 long graph

http://xingyun.jd.com/codingRoot/wangsongsong1/sec_langgraph_algorithm_opt/

e. 9N模型训练

☰ 五：9N-LLM-Flow 超大规模训练

f. dify学习文档（和autosec一致）

<https://docs.dify.ai/zh-hans/guides/workflow/node/llm>

其中变量赋值只能写入“会话变量、循环变量”中，工作流不支持。

g. autosec学习文档

☰ autosec平台大模型应用搭建指南

h. cursor 命令行选项

<https://www.runoob.com/cursor/cursor-cursor-command.html>

i. 月报

☰ 安全大模型月报M5

j. 大模型网关接口

☰ 大模型网关接口文档

4. LLM相关知识

a. llm的三个角色

"system"角色有助于通过分配特定行为给聊天助手来创建对话的上下文或范围。

"user"角色指示消息/提示来自最终用户或人类。

"assistant"角色代表响应最终用户提示的实体。

b. 神经网络参数计算epoch、batch、batch size、step与iteration

<https://blog.csdn.net/zhebushibiaoshifu/article/details/131086145>

元素	概念	原始数据1500
epoch	全部数据训练几轮次	epoch
batch	每轮次数据分几批训练	batch
batch size	每批次训练数据量	1500/batch
step(等同于iteration)	batch*epoch	1500/batch * epoch

c. fp16、bf16、fp32

格式	总位数	指数位	尾数位	动态范围	精度	适用场景
fp32	32	8	23	非常大	非常高	训练、推理通用
fp16	16	5	10	较小	中等	显存紧张、推理加速
bf16	16	8	7	和fp32一样大	介于fp16和fp32	大模型训练、分布式

d. *Adam 优化器（补充数学原理详解）

核心：为每个参数计算自适应学习率。

工作方式：动态调整步长，在较简单的区域中步长较大，在较复杂的区域中步长较小，确保更有效且更快速地到达最低点，即最小损失。

e. 输出token计算方式

LLM输出的概率分布，是对词表中所有token的概率预测，每次只能从词表里选一个token作为下一个输出。

f. llm显存内存计算公式

计算公式参考: https://blog.csdn.net/2401_85373691/article/details/145449755

- 1 最小推荐内存 = (模型基础内存 + 工作内存 + 系统预留) × 1.2 其中: - 工作内存 = KV Cache + 激活值 + 临时计算空间 - KV Cache $\approx 2 \times \text{num_layers} \times \text{batch_size} \times \text{seq_length} \times \text{hidden_size} \times \text{bytes_per_element}$ - 激活值 $\approx \text{num_layers} \times \text{batch_size} \times \text{seq_length} \times \text{hidden_size} \times \text{bytes_per_element}$ - bytes_per_element = 4 (FP32) 或 2 (FP16) - 系统预留 $\approx$ 基础内存的50%
- 2 最小推荐显存 = (模型基础内存 + CUDA开销 + 工作内存) × 1.2 其中: - CUDA开销 $\approx$ 基础内存的15% - 工作内存 = KV Cache + 激活值 + CUDA缓存 - bytes_per_element = 4 (FP32) 或 2 (FP16)

g. 模型训练过程

1. <https://zhuanlan.zhihu.com/p/636270877>

5. Llm技术前沿

a. Browser-use (*尝试使用)

是一个旨在将 AI “智能体” (Agents) 与真实浏览器进行交互的 Python 库, 可以轻松实现浏览器自动化。在配合 LLM (如 GPT 系列) 使用时, 浏览器-use 能够让你的智能体发起对网页的访问、操作页面元素、收集信息、执行脚本等, 从而扩展 AI 应用的落地场景。

介绍文档:

<https://www.cnblogs.com/risheng/p/18792927>

官方文档:

<https://docs.browser-use.com/quickstart>

6. RAG: 检索增强生成 retrieval

文档参考:

<https://docs.dify.ai/zh-hans/learn-more/extended-reading/retrieval-augment/hybrid-search>

RAG 检索环节中的主流方法是向量检索, 即语义相关度匹配的方式。技术原理是通过将外部知识库的文档先拆分为语义完整的段落或句子, 并将其转换 (Embedding) 为计算机能够理解的一串数字表达 (多维向量), 同时对用户问题进行同样的转换操作。

autosec设置

TopK: 用于筛选与用户问题**相似度最高的文本片段**。系统同时会根据选用模型上下文窗口大小动态调整片段数量。系统默认值为 3。

Score 阈值： 用于设置**文本片段筛选的相似度阈值**，即：只召回超过设置分数的文本片段。系统默认关闭该设置，即不会对召回的文本片段相似值过滤。打开后默认值为 0.5 。

Rerank 模型： 系统会在语义检索后**对已召回的文档结果再一次进行语义重排序**，优化排序结果。设置 Rerank 模型后，TopK 和 Score 阈值设置仅在 Rerank 步骤生效。

a. 混合搜索

对于大多数文本搜索的情景，首要的是确保潜在最相关结果能够出现在候选结果中。向量检索和关键词检索在检索领域各有其优势。混合搜索正是结合了这两种搜索技术的优点，同时弥补了两方的缺点。

向量检索和传统关键词检索优劣对比：

除了能够实现复杂语义的文本查找，**向量检索**还有其他的优势：

- 相近语义理解（如老鼠/捕鼠器/奶酪，谷歌/必应/搜索引擎）
- 多语言理解（跨语言理解，如输入中文匹配英文）
- 多模态理解（支持文本、图像、音视频等的相似匹配）
- 容错性（处理拼写错误、模糊的描述）

虽然向量检索在以上情景中具有明显优势，但有某些情况效果不佳。比如：

- 搜索一个人或物体的名字（例如，伊隆·马斯克，iPhone 15）
- 搜索缩写词或短语（例如，RAG，RLHF）
- 搜索 ID（例如，`gpt-3.5-turbo`，`titan-xlarge-v1.01`）

而上面这些缺点恰恰都是传统关键词搜索的优势所在，**传统关键词搜索**擅长：

- 精确匹配（如产品名称、姓名、产品编号）
- 少量字符的匹配（通过少量字符进行向量检索时效果非常不好，但很多用户恰恰习惯只输入几个关键词）
- 倾向低频词汇的匹配（低频词汇往往承载了语言中的重要意义，比如“你想跟我去喝咖啡吗？”这句话中的分词，“喝”“咖啡”会比“你”“想”“吗”在句子中承载更重要的含义）

b. rerank重排序

重排序一般都放在搜索流程的最后阶段，非常适合用于合并和排序来自不同检索系统的结果。因为混合检索能够结合不同检索技术的优势获得更好的召回结果，但在不同检索模式下的查询结果需要进行合并和归一化。

c. 召回

在应用内关联了多个知识库，此时需要应用召回策略决定从哪些知识库中检索内容。

根据用户意图同时匹配所有知识库，从多路知识库查询相关文本片段，经过重排序步骤，从多路查询结果中选择匹配用户问题的最佳结果，需配置 Rerank 模型 API。在多路召回模式下，检索器会在所有与应用关联的知识库中去检索与用户问题相关的文本内容，并将多路召回的相关文档结果合并，并通过 Rerank 模型对检索召回的文档进行语义重排序。

i. 召回测试

1. **评估召回率**：计算模型的召回率（Recall），即模型正确检索到相关信息的比率。召回率是衡量模型检索能力的重要指标。

7. Function Calling（函数调用）

Function Calling是AI模型调用函数的机制。

核心思想：统一思想，规范描述

function Calling机制赋予了大模型“调用外部工具”的能力，比如查天气、查资料、下订单、执行计算等。通过Function Call，大模型可以调用各种API、工具、数据库、插件，甚至别的AI模型，极大扩展了自身能力边界。

问题：没有统一的标准，每家大厂的不一样

典型应用：Coze

8. *MCP 大模型上下文协议


规范agent和tool之间的交互

MCP是一个标准协议，使大模型与API无缝交互。通过标准化的接口（如基于JSON-RPC 的通信）实现上下文的动态传递和工具的灵活调用。

用结构化、标准化的协议，把“任务状态、历史步骤、外部调用结果、子任务”等上下文信息完整地传递给大模型，模型每次决策时都能“看见”整个任务流程和全局状态。

MCP允许AI模型通过统一的协议与各种外部资源进行交互。MCP的目的是简化AI模型与外部工具之间的交互流程，使其更加标准化和可复用，从而提升AI系统的灵活性和效率。

实例：（规范工具输入输出的需求，description是最重要的内容，用于给agent该工具的描述）




典型应用：字节Manus

架构：

<https://mp.weixin.qq.com/s/rkj5MKU4UZhYdrbXZJgmeQ>

以 Manus 为例：Multi-Agent 智能体系统工作流程



Manus是指一个由中国AI公司开发的通用型AI Agent产品。

9. 工作流与智能体区别

工作流是指一系列**按照预定义规则和顺序执行的任务**或步骤，通常用于描述业务流程或操作的结构化执行路径。它强调的是过程的标准化和自动化，确保任务按部就班地完成。

- **例子：**在软件开发中，一个典型的工作流可能是“代码提交 -> 代码审查 -> 测试 -> 部署”，每个步骤都有明确的前后依赖和触发条件。

Agent 是一个具备一定智能的实体，能够感知环境、自主决策并执行行动。它通常基于 AI 技术（如机器学习、强化学习），强调适应性和自主性。

AI Agent是一个**自主运行的智能系统**，利用Function Calling和MCP来分析和执行任务，实现特定目标。

- **例子：**一个**客服 Agent** 能根据用户输入判断意图，自主选择回复内容，甚至调用工具解决问题，而无需严格遵循固定步骤。

维度	工作流	Agent
适用场景	结构化、可重复的任务	非结构化、需要灵活应对的任务
例子	自动化部署流水线、订单处理流程	智能客服、自动驾驶、任务调度助手
灵活性	低，固定路径	高，动态调整
复杂度	简单，易于设计和调试	复杂，需训练或配置
人类干预	通常需要人为触发或监督	可独立运行，减少干预

工作流：适合企业中那些明确定义好、重复性高的业务流程，比如财务报销、文件归档。

Agent：适合需要实时决策或处理不确定性的场景，比如聊天机器人、推荐系统。

10. lang chain和 lang graph

1. <https://zhuanlan.zhihu.com/p/28852751523>

LangChain 更适合线性和基于工具的调用，而 LangGraph 更适合复杂的、多路径和具有反馈机制的 AI 工作流。

如果开发者需要持久化存储记忆，可以引入特定的节点，用于将记忆和变量存入外部数据库，以便后续检索。

Langchain

是一个开源框架，它允许开发人员将像 GPT-4 这样的大型语言模型与外部的计算和数据源结合起来。

核心组件：

Prompt Templates：这些模板让你避免硬编码文本输入。你可以动态地将用户输入插入到模板中，并发送给语言模型。

Tool（工具）：是可以在链中被调用的代码函数，或由 Agent 触发，以与外部系统交互。

(Indexes：索引帮助你从语言模型中提取相关信息。)

Chains：链允许你将多个组件组合在一起，解决特定的任务，并构建完整的语言模型应用程序。

Agents：代理允许语言模型与外部API交互。

lang graph

图（Graph）的方式编排工作流。由于其在 AI Agent、过程式代码和其他工具之间的灵活处理能力，它更适用于**线性链、分支链**或简单 Agent 系统难以满足需求的**复杂应用场景**。LangGraph 设计用于处理**更复杂的条件逻辑和反馈循环**，比 LangChain **更加强大**。

核心组件：

- Graph（图）是一种灵活的工作流组织方式，支持调用 LLM、工具、外部数据源、过程式代码等。LangGraph 还支持循环图（Cyclical Graph），即可以创建循环和反馈机制，使得某些节点能够被多次访问。
- Node（节点）表示**工作流**中的步骤，例如 LLM 查询、API 调用或工具执行。

- **Edge** (边) 和 **Conditional Edge** (条件边): 边用于连接节点, 定义信息流向, 使一个节点的输出作为下一个节点的输入。条件边允许在满足特定条件时, 将信息从一个节点流向另一个节点。开发者可以自定义这些条件。
- **State** (状态) 表示应用程序的当前状态, 随着信息在图中流动而更新。状态是一个开发者定义的可变 TypedDict 对象, 包含当前执行图所需的所有相关信息。LangGraph 会在每个节点自动更新状态。**负责管理记忆。**
- **Agent 或 LLM**: LLM 仅负责对输入生成文本响应。而Agent 能力则允许图中包含多个节点, 分别代表 Agent 的不同组件 (如推理、工具选择和工具执行)。Agent 可以决定在图中采取哪条路径、更新图的状态, 并执行比单纯文本生成更多的任务。

11. 信息安全术语

a. aisoc

artificial Intelligence Security Operations Center AI驱动的安全运营中心

i. oauem

OAUEM (Operational Analytics Unified Endpoint Management, 运营分析统一终端管理告警)。其核心是通过终端数据分析实现安全运营的自动化检测。

ii. NIDS

NIDS (Network Intrusion Detection System, 网络入侵检测系统告警)

b. 指纹技术

在网络安全中, 指纹探测是一种通过分析目标系统或服务的特征信息来识别其类型、版本、配置等细节的技术。指纹探测通常用于识别系统或服务的“身份”

常见指纹检测的对象

- 1、CMS信息: 比如大汉CMS、织梦、帝国CMS、phpcms、ecshop等;
- 2、前端技术: 比如HTML5、jquery、bootstrap、pure、ace等;
- 3、Web服务器: 比如Apache、lighttpd、Nginx、IIS等;
- 4、应用服务器: 比如Tomcat、Jboss、weblogic、websphere等;
- 5、开发语言: 比如PHP、Java、Ruby、Python、C#等;
- 6、操作系统信息: 比如linux、win2k8、win7、kali、centos等;
- 7、CDN信息: 是否使用CDN, 如cloudflare、360cdn、365cyd、yunjiasu等;
- 8、WAF信息: 是否使用waf, 如Topsec、Jiasule、Yundun等;
- 9、IP及域名信息: IP和域名注册信息、服务商信息等; 10、端口信息: 有些软件或平台还会探测服务器开放的常见端口。

c. 渗透测试

1. **渗透测试 (Penetration Testing)** 是一种模拟黑客攻击的方法，用于主动评估计算机系统、网络、应用程序或组织的安全性。
2. 渗透测试是一项在计算机系统上进行的授权模拟攻击，旨在对其安全性进行评估。渗透测试人员使用与攻击者相同的工具、技术和流程，来查找和展示系统弱点^{对业务带来的影响}。

d. 微步查询

微步威胁情报查询是由中国网络安全公司**微步在线 (ThreatBook)** 提供的**专业化威胁情报服务**，旨在帮助企业^{和安全团队}快速识别、分析和应对网络威胁。其核心是通过对全球范围内的恶意IP、域名、文件哈希（如MD5、SHA256）、URL等威胁指标（Indicators of Compromise, IoC）进行实时检测和关联分析，为用户提供精准的威胁判定和上下文信息。

e. ddos攻击

DDoS攻击（Distributed Denial of Service，**分布式拒绝服务攻击**）是一种通过**大规模协同的恶意流量**淹没目标服务器、网络或服务，使其无法正常响应合法用户请求的网络攻击手段。其核心目的是通过耗尽目标的带宽、计算资源或系统容量，导致服务中断或性能严重下降。

12. 专业术语

a. http请求

在 Dify 中，HTTP 请求节点的作用类似于一个“信使”，它帮你向其他网站或服务（API）发送请求并获取数据。下面用最直白的方式解释它的工作原理和配置方法：

1. 什么是 HTTP 请求？

想象你想知道北京的天气，但自己不会预测。于是你打开手机天气 App，App 会替你^{去问气象局的服务器}：“北京现在多少度？”——这个过程就是 HTTP 请求。

你（用户）→ App（HTTP 请求节点）→ 气象局服务器（API）→ 返回数据（如 25°C）

2. 为什么能实现查询？

因为很多网站和服务（如天气、地图、翻译）都提供了 API（数据接口），允许你通过特定格式的请求获取它们的数据。

例如：

天气 API：发送城市名 → 返回温度

翻译 API：发送文本 → 返回翻译结果

HTTP 请求节点就是帮你发送这些“问题”并接收“答案”的工具。

b. Megatron

NVIDIA Megatron 是一个基于 PyTorch 的框架，用于训练基于 Transformer 架构的巨型语言模型。

c. URL

（统一资源定位符）是因特网中的唯一资源的地址。

d. 流式数据

流式数据 (Streaming Data) 是指源源不断、实时产生、持续流动的数据。

这些数据不是一次性全部产生出来，而是像“水流”一样，持续不断地到达系统。

13. 模型对齐

指的是让AI模型的行为、输出和人类的期望、价值观保持一致。

模型对齐的实现方式

(1) 技术层面

- **RLHF (人类反馈强化学习)**

让人类标注员对模型输出进行打分，模型根据这些反馈进行优化，逐步学会“什么样的输出更符合人类期望”。

- **指令微调 (Instruction Tuning)**

用大量“人类指令+期望回复”数据微调模型，让它更好地理解和执行人类意图。

- **安全规则与过滤**

加入安全策略、内容过滤、拒绝危险请求等。

(2) 理念层面

- **价值观灌输**

让模型输出符合人类社会的主流价值观、道德规范。

- **目标一致性**

保证模型的“目标函数”与人类的目标一致，避免“工具变主人”。

- **用户定制对齐**

针对不同用户、不同场景，定制化对齐不同的偏好和需求。

14. cursor学习

a. 命令行选项

<https://www.runoob.com/cursor/cursor-cursor-command.html>

b. 智能补全与代码生成

Users > tianqixin > Desktop > runoob_test.py

```
1 print("hello runoob")
```

输入 pri 后会预测你要编写的代码

注释写功能，会自动提示要生成的代码（tab键）

Users > tianqixin > Desktop > runoob_test.py

```
1 print("hello runoob")
```

```
2
```

```
3 # 计算平均数
```

```
def average(values):  
    return sum(values) / len(values)
```

```
# 测试
```

```
print(average([1, 2, 3, 4, 5]))
```

我在注释上写计算平均数
会自动提示要生成的代码

15. autosec

a. 学习操作

1. 聊天助手可以标注回复（设定指定问题的回答）



2. 提示词进阶优化，有训练数据设定。



出现报错首先自查是否时是变量设置有问题

3. 当前搜狗工具的微信公众号爬取有问题

b. agent

c. Jinja

可以生成任何基于文本的格式（HTML、XML、CSV、LaTeX等）。Jinja模板不需要有特定的扩展名：`.html`、`.xml` 或任何其他扩展名都可以。

16. 九数平台

参考资源： [一、9N-LLM-Flow 持续预训练和SFT](#)

SSH连接

分三块操作(当前vs code连接未解决)

 [本地ssh连接notebook终端操作步骤](#)

vscode连接时XHR failed问题解决：<https://zhuanlan.zhihu.com/p/671718415>（手动本地下载传输）

《《

1. 本地SSH连接Notebook实例

2. 本地vscode连接notebook实例

3. ssh连接失败常见问题

创建实例

 [最佳实践：从模型开发到部署](#)

文件路径

注意△：模型权重文件不要和训练配置文件放在一起！

1为模型训练配置文件路径（下载一次即可），下载流程：

```
1 git clone git@coding.jd.com:9N-ModelZoo/qwen.git
2 cd qwen
3 # workflow.py 表示启动程序入口, 同Pretrain、SFT、对齐微调完全一致, 可复用
4 # configs/*_flow.json 表示训练参数配置文件: 训练类型、模型类型、训练超参等
```

2为九数配置文件路径

/ llm-train / qwen /		1
Name		Last Modified
configs		6 days ago
log		6 days ago
mp_tools		6 days ago
trained		6 days ago
magnus-xuzhenni-020...		6 days ago
magnus.py	2	6 days ago
README.md		6 days ago
workflow.py		6 days ago

qwen2-7B模型以及权重下载路径（按选择的模型下载），下载流程：

```
1 # 下载预训练参数到个人/CFS路径 ($MODEL_PATH).
2 git clone git@coding.jd.com:9N-NLP-ModelsHub/Qwen2-7B-Instruct.git
3 cd Qwen2-7B-Instruct
4 wget -i weight_url.txt
5 cd ..
```

Filter files by name



/ llm-train /

Name



Last Modified

log	6 days ago
models	5 minutes ago
qwen	6 days ago
Qwen2-7B-Instruct	6 days ago
Qwen3-0.6B	6 days ago
sft_full	6 days ago
trained	6 days ago
Qwen2-7B-Instruct.inc...	6 days ago
Qwen2-7B-Instruct.lock	6 days ago
train8.jsonl	6 days ago

1为模型配置文件路径

2为模型微调文件

/ ... / qwen / configs /	
Name	Last Modified
mp	36 minutes ago
deepspeed.json	36 minutes ago
dpo_flow.json	36 minutes ago
generate_flow.json	36 minutes ago
ipo_flow.json	36 minutes ago
kto_flow.json	36 minutes ago
orpo_flow.json	36 minutes ago
pretrain_flow.json	36 minutes ago
sec_eval_flow.json	36 minutes ago
sft_flow.json	27 minutes ago
simpo_flow.json	36 minutes ago

运行脚本

转到模型训练配置文件路径下输入（不能缺少增加任何字符!）：

```
9Nctl start --mode=magnus --desc "test13_checkpoint-80" -g llm-sec --enable_queue -
-reclaimable=False --start_timeout=3600 --ratio=0.99 --tensorboard .
```

关闭任务

http://easyalgo.jd.com/model/task?current_app_id=686

检测平台直接点“删除”

九数算法中台

LLM-SEC

工作空间详情

AI广场

模型广场

数据广场

数据清洗

特征中心

样本中心

模型开发与训练

Notebook建模

可视化建模

脚本建模

训练任务

调度任务

超参研究

模型管理

模型优化

模型评测

在线推理

批量推理

推理库

AIFlow工作流

工作流管理

组件管理

AI资产

模型管理

训练任务

方便查看、监控、诊断，管理各类训练任务；组内其他人的训练任务仅可由组管理员删除。
为了及时释放任务占用的各种资源，中台会定期清理已完成3天以上的任务。
个人任务和组任务只展示活跃任务，历史任务展示未超过30天的被清理的个人及组任务。

个人任务 空间任务 历史任务 资源建议

操作步骤引导

数据准备 模型准备 模型训练 查看任务

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作

训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控 请求资源 保留时间 任务优先级 可被驱逐 操作


训练任务

任务名称 描述 创建时间 状态 CPU 内存 GPU 运行时长 结束时间 监控

检测平台

http://easyalgo.jd.com/model/task?searchcache=true¤t_app_id=686


```
1  {
2      "task_type": "sft",
3      "model_type": "qwen",
4      "peft_type": "full",
5      "custom": {
6          "train_dir":
7      "/media/cfs/lijinqi13/code/TinyAn/data/train13.jsonl",
8          "eval_dir":
9      "/media/cfs/lijinqi13/code/TinyAn/data/eval13.jsonl",
10         "pretrained_model": "/media/cfs/lijinqi13/model/Qwen2.5-7B-
11     Instruct",
12         "max_length": 6144
13     },
14     "train": {
15         "output_dir":
16     "/media/cfs/lijinqi13/model/TinyAnModel/train13",
17         "logging_steps": 1,
18         "fp16": false,
19         "bf16": true,
20         "logging_dir":
21     "/media/cfs/lijinqi13/code/TinyAn/configs/log",
22         "learning_rate": 1e-05,
23         "per_device_train_batch_size": 1,
24         "report_to": "tensorboard",
25         "save_strategy": "epoch",
26         "weight_decay": 0.01,
27         "max_grad_norm": 1,
28         "warmup_ratio": 0.03,
29         "lr_scheduler_type": "cosine",
30         "optim": "adamw_torch",
31         "gradient_accumulation_steps": 16,
32         "num_train_epochs": 10,
33         "eval_strategy": "steps",
34         "eval_steps": 4,
35         "eval_accumulation_steps": 5,
36         "prediction_loss_only": false,
37         "label_names": [
38             "labels"
39         ],
40         "per_device_eval_batch_size": 1,
41         "deepspeed": "./configs/deepspeed.json",
42         "dataloader_num_workers": 8
43     }
44 }
```



推理

```
1 {
2   "task_type": "generate",
3   "model_type": "qwen",
4   "generate": {
5     "model_dir":
6       "/media/cfs/lijinqi13/model/TinyAnModel/train13/checkpoint-80",
7     "batch_size": 4,
8     "data_loader_num_workers": 4,
9     "input_path":
10       "/media/cfs/lijinqi13/code/TinyAn/data/test13.jsonl",
11     "output_path":
12       "/media/cfs/lijinqi13/code/TinyAn/data/test_generate_output13_checkpoint-80.json",
13     "top_k": -1,
14     "top_p": 1.0,
15     "temperature": 1.0,
16     "max_tokens": 6144,
17     "use_beam_search": false
18   }
19 }
```

magus.py (配置集群) config 九数配置文件

如果卡不够, 可以把第13、25行取消注释

```
1  # /bin/python
2  #framework = "magnus:ascend_8.0.rc2-torch2.1-magnus-gpu-
   test_1.3.0.112233"
3  #framework = "magnus:ascend_8.0.rc2-torch2.1-magnus-gpu_v1.3.1" #
   训练
4  framework = "magnus:ascend_8.0.rc3-torch2.1-magnus-gpu_v1.3.3.beta1"
5  #framework = "magnus:ascend_8.0.rc2-torch2.1-magnus-gpu_v1.3.1"
6
7  python_home="/usr/local/anaconda3/bin"
8
9  log_dir="/media/cfs/lijinqi13/code/TinyAn/configs/log"
10
11  entrance_filename="workflow.py"
12  roles = ['master']
13  #roles = ['master', 'worker']
14
15  global_parameters = dict(
16      config_path = "configs/generate_flow.json"
17  )
18
19  master = dict(
20      count=1,
21      cpu=10,
22      mem=100,
23      gpu="ascend910:1"
24  )
25  # worker = dict(count=1,
26  #               cpu=30,
27  #               mem=800,
28  #               gpu="ascend910:8")
29
30  cloud_tags={'cluster': "lfga-cluster", 'node': "9n-a100,train",
              'use_gpu': True}
```